

Perbandingan Model CNN Scratch dan MobileNet V2 untuk Klasifikasi Gambar Bencana Alam

2802489490 - Matthew Owen Gunawan

2802456706 - Gihon Given Imanuello Hutahaea

Data Science, Universitas Bina Nusantara, Indonesia

Data Science, Universitas Bina Nusantara, Indonesia

Alamat: Jl. Raya Kb. Jeruk No.27, RT.1/RW.9, Kemanggisan, Kec. Palmerah, Kota
Jakarta Barat, Daerah Khusus Ibukota Jakarta 11530

Bab 1

Pendahuluan

1.1. Latar Belakang

Penanganan krisis darurat akibat bencana alam selalu menuntut kecepatan. Apalagi dengan letak geografis kita, kerentanan wilayahnya sangat tinggi. Gempa bumi, longsor, banjir, dan kebakaran kawasan padat (urban fire) sering terjadi dan daya rusaknya luar biasa. Dalam kondisi yang serba kacau, identifikasi awal mengenai jenis insiden ini sangat krusial. Tim yang turun ke lapangan amat bergantung pada informasi tersebut. Mereka membutuhkannya untuk memutuskan alokasi logistik dan alat evakuasi yang tepat sasaran.

Berpegang pada urgensi ini, proyek ini merancang sebuah sistem klasifikasi otomatis. Pemodelannya menggunakan framework PyTorch untuk mengevaluasi dua arsitektur CNN. Studi ini membandingkan secara langsung Model 1, yakni CNN yang dibangun murni dari awal (from scratch), dengan Model 2 yang berbasis MobileNetV2 melalui teknik Transfer Learning. Melalui perbandingan metrik performa nanti, harapannya kita bisa menemukan satu model yang tidak cuma akurat. Tetapi model tersebut juga harus efisien beban komputasinya supaya siap diterapkan langsung dalam sistem tanggap darurat bencana.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang kami buat, ada beberapa rumusan masalah yang bisa kami klasifikasi:

- Bagaimana merancang dan melatih model 1 berupa arsitektur Convolutional Neural Network (CNN) yang dibangun dengan menggunakan metode scratch untuk mengenali 4 kelas bencana alam?

- Bagaimana menerapkan pendekatan Transfer Learning menggunakan pre-trained model sebagai Model 2 dalam memproses dataset citra bencana alam yang sama?
- Bagaimana perbandingan performa klasifikasi antara model yang dibangun dengan metode scratch dan model pre-trained dengan metode MobileNet V2 berdasarkan metrik evaluasi klasifikasi accuracy, precision, recall, dan f1-score?

1.3. Tujuan Proyek

Berdasarkan rumusan masalah yang telah dirancang, ada beberapa tujuan yang ingin dicapai dalam proyek ini:

- Merancang, membangun, dan melatih Model 1 berupa arsitektur Convolutional Neural Network (CNN) dari awal (from scratch) berbasis framework PyTorch untuk mengklasifikasikan gambar bencana ke dalam empat kategori utama.
- Mengimplementasikan pendekatan Transfer Learning menggunakan pre-trained model sebagai model 2 atau model pembanding untuk mengekstraksi fitur visual secara optimal pada dataset gambar bencana alam.
- Menganalisis dan membandingkan performa model berdasarkan metrik evaluasi klasifikasi accuracy, precision, recall, dan f1-score antara model 1 dan Model 2 guna menentukan pendekatan pemodelan yang paling efektif untuk klasifikasi citra bencana alam.

Bab 2


Metodologi

2.1. Metode Penyelesaian Masalah

Penyelesaian masalah dalam penelitian ini menggunakan pendekatan eksperimental kuantitatif berbasis Deep Learning. Strategi utama yang digunakan adalah studi komparatif (head-to-head), di mana proyek ini merancang dan mengevaluasi dua arsitektur klasifikasi gambar secara paralel untuk memecahkan masalah identifikasi citra bencana alam.

Metode ini dipilih untuk membandingkan performa antara arsitektur model baseline konvensional dengan arsitektur yang lebih mutakhir. Secara spesifik, eksperimen dibagi menjadi dua jalur pemodelan: pertama, merancang Convolutional Neural Network (CNN) secara murni dari awal (from scratch) sebagai Model 1. Kedua, mengimplementasikan metode Transfer Learning menggunakan arsitektur pre-trained MobileNetV2 sebagai Model 2.

Kedua model tersebut kemudian dilatih dan diuji menggunakan dataset dan metrik evaluasi yang identik secara global (meliputi Accuracy, Precision, Recall, dan F1-Score). Seluruh peta jalan dari metode penyelesaian masalah ini, mulai dari penerimaan data mentah (data ingestion) hingga penarikan kesimpulan komparatif akhir, dapat direpresentasikan secara visual melalui flowchart alur kerja berikut:



2.2. Tahapan Penyelesaian Masalah

Berdasarkan diagram alir metode penyelesaian masalah, berikut adalah uraian dari setiap tahapan yang dilakukan dalam proyek ini:

- Pengumpulan dan Eksplorasi Data (Exploratory Data Analysis)

Pada tahap ini, dataset citra bencana alam yang memuat empat kelas kategori utama (Earthquake, Landslide, Urban Fire, dan Water Disaster) dikumpulkan dan dieksplorasi. Eksplorasi data difokuskan pada pemahaman karakteristik dataset menggunakan pustaka `datasets.ImageFolder`. Proses ini mencakup penghitungan total jumlah gambar dan sebaran jumlah citra pada masing-masing kelas (menggunakan `collections.Counter`) untuk mendeteksi apakah terdapat ketidakseimbangan data (data imbalance). Selain itu, dilakukan pengecekan statistik citra, meliputi perhitungan rata-rata resolusi, nilai minimum dan maksimum resolusi, serta rasio aspek (aspect ratio) dari setiap gambar untuk menentukan strategi penyesuaian ukuran gambar di tahap selanjutnya.

- Pra-pemrosesan Data (Data Preprocessing)

Karena data gambar mentah memiliki resolusi dan ukuran yang sangat beragam mulai dari 161x119 sampai 2048x1350, tahap ini berfokus pada standardisasi gambar agar siap dan optimal saat diproses oleh model. Proses ini memanfaatkan modul `torchvision.transforms` yang di dalamnya mencakup penyesuaian ukuran gambar (resizing) ke dimensi piksel yang seragam, mengubah format gambar dari format visual menjadi format komputasi tensor PyTorch (`ToTensor()`), serta dapat melibatkan normalisasi nilai piksel agar model dapat mengenali pola dengan lebih stabil dan cepat selama proses konvolusi.

- Pembagian Dataset (Data Splitting)

Setelah diproses dan dibentuk menjadi tensor, keseluruhan dataset dipisahkan menjadi beberapa himpunan untuk memfasilitasi pelatihan yang tervalidasi secara objektif. Menggunakan fungsi `random_split` dari PyTorch, data dibagi secara proporsional menjadi training set (data latih

untuk memperbarui bobot model, validation set, dan test set. Setiap himpunan data ini kemudian dimuat ke dalam DataLoader yang akan mengatur proses distribusi data dalam bentuk tumpukan batch selama iterasi pemodelan berjalan.

- Perancangan Arsitektur Model

Pada tahap ini, rancangan arsitektur model dibagi menjadi dua pendekatan eksperimental. **Model 1 (CNN From Scratch)** dibangun sepenuhnya dari awal tanpa menggunakan bobot yang sudah terlatih. Proses ekstraksi fitur pada model ini mengandalkan kombinasi lapisan konvolusi, *Batch Normalization* untuk menstabilkan gradien, serta *Max Pooling* guna mereduksi beban komputasi. Hasil ekstraksi visual tersebut kemudian diratakan (*flatten*) dan diteruskan ke *Fully Connected Layer*. Sebagai langkah antisipasi terhadap *overfitting*, lapisan *Dropout* sebesar 50% disisipkan tepat sebelum lapisan keluaran akhir yang memuat 4 neuron sesuai dengan jumlah kategori bencana.

Sementara itu, **Model 2 (Transfer Learning - MobileNetV2)** memanfaatkan arsitektur ringan yang sudah matang dari dataset ImageNet. Seluruh lapisan konvolusi dasar (*feature extractor*) pada model ini sengaja dibekukan (*frozen*) agar kemampuannya dalam mengenali pola visual tidak hilang dan sistem tidak perlu belajar lagi dari nol. Modifikasi murni hanya dilakukan dengan memotong *classifier* bawaan MobileNetV2 dan menggantinya dengan *Fully Connected Layer* baru. Lapisan ujung yang baru ini dirancang secara spesifik untuk mengklasifikasikan 4 jenis bencana alam target, sehingga proses pelatihan menjadi jauh lebih cepat dan efisien secara komputasi.

- Training Process

Model yang telah dirancang kemudian dilatih menggunakan data latih yang dipandu oleh fungsi optimasi (`torch.optim`) dan fungsi kerugian / loss function seperti Cross Entropy Loss. Proses pelatihan ini dilakukan

melalui beberapa epoch siklus. Pada setiap iterasi, model melakukan forward pass untuk memprediksi probabilitas kelas, mengevaluasi kesalahan loss dari prediksi tersebut, dan melakukan backpropagation untuk mengoreksi serta memperbarui bobot weights. Performa loss dan akurasi model selalu dievaluasi terhadap data validasi di penghujung epoch guna memantau konvergensi sekaligus menghindari indikasi overfitting.

- Evaluasi Performa Model

Setelah iterasi pelatihan selesai, kedua model diuji secara definitif menggunakan test set yang belum pernah disentuh oleh model selama fase training. Tahapan ini menggunakan fungsi kustom yang dipadukan dengan pustaka sklearn.metrics. Hasil prediksi dari model terhadap gambar pengujian dibandingkan dengan label aslinya untuk menghasilkan sebuah Classification Report. Metrik evaluasi yang dihitung secara komprehensif meliputi Accuracy, Precision, Recall, dan F1-Score. Angka-angka ini pada akhirnya digunakan untuk membandingkan secara langsung performa klasifikasi antara pendekatan scratch (Model 1) dan pendekatan Transfer Learning (Model 2).

Bab 3

Hasil & Analisa


3.1. Skenario Eksperimen dan Parameter Tuning

Eksperimen dalam penelitian ini dilakukan dengan membandingkan dua arsitektur model melalui skenario parameter tuning yang disesuaikan dengan kapasitas masing-masing model.

1. **Model 1 (CNN From Scratch):** Dilatih selama 15 epoch menggunakan optimizer Adam. Untuk mengontrol overfitting pada arsitektur dasar ini, lapisan Dropout sebesar 50% diterapkan pada Fully Connected Layer.
2. **Model 2 (MobileNetV2):** Menggunakan pendekatan Transfer Learning di mana parameter konvolusi dasar dibekukan (frozen). Model ini menggunakan optimizer AdamW yang memiliki kemampuan penalti bobot (weight decay) lebih baik. Untuk optimasi tingkat lanjut, diterapkan learning rate scheduler berupa Cosine Annealing untuk menurunkan laju pembelajaran secara halus, serta fitur Early Stopping untuk menghentikan pelatihan secara otomatis apabila tidak ada perbaikan pada validation loss.


3.2. Analisa Data Eksploratif (Karakteristik Visual Kelas)

Sebelum pelatihan, analisis terhadap distribusi rata-rata piksel RGB (Red, Green, Blue) mengonfirmasi bahwa setiap kategori bencana memiliki fitur visual tingkat rendah (low-level features) yang unik. Kelas Urban Fire didominasi mutlak oleh spektrum Red akibat kobaran api, Land Slide didominasi campuran Red dan Green (warna tanah/cokelat), Earthquake menunjukkan nilai RGB yang rendah dan rapat (warna monokrom puing), sementara Water Disaster memiliki intensitas tertinggi di seluruh channel karena pantulan cahaya pada air. Karakteristik ini memastikan bahwa lapisan konvolusi pada model memiliki sinyal visual yang valid untuk diekstraksi.



3.3. Hasil Eksperimen Model 1 (CNN From Scratch)

Berdasarkan hasil pelatihan, Model 1 menunjukkan indikasi limitasi kapasitas dalam melakukan generalisasi.




- Analisa Kurva:** Pada kurva akurasi, Train Accuracy berhasil mencapai 75%, namun Validation Accuracy mengalami stagnasi di kisaran 64%. Hal yang sama terlihat pada kurva Loss, di mana Train Loss terus menurun hingga 0.20, tetapi Validation Loss tertahan (plateau) di angka 0.80. Jarak (gap) yang melebar antara metrik latih dan validasi ini merupakan indikator terjadinya overfitting.

- **Analisa Classification Report:** Pada pengujian data independen, Model 1 hanya mencatatkan akurasi global sebesar 66%. Model ini sangat rentan terhadap class imbalance, terbukti dari gagalnya model mendeteksi 68% kejadian tanah longsor (Recall 0.32) dan performa yang sangat buruk pada kelas minoritas Earthquake (F1-Score 0.18).

3.4. Hasil Eksperimen Model 2 (MobileNetV2)

Implementasi Transfer Learning dengan parameter tuning tingkat lanjut pada Model 2 berhasil menyelesaikan permasalahan yang ada pada Model 1 secara komprehensif.



- **Analisa Kurva:** Berkat fitur extractor yang matang dari ImageNet, Model 2 menunjukkan konvergensi yang sangat sehat (Good Fit). Kurva Train dan Validation bergerak sangat rapat berdampingan. Akurasi validasi berhasil stabil di kisaran 82%-84%, sementara tingkat kesalahan (Validation Loss) sukses ditekan turun secara signifikan hingga menyentuh kisaran 0.50 tanpa ada indikasi memantul naik (divergensi).
- **Analisa Classification Report:** Performa Model 2 pada fase testing melonjak drastis dengan **akurasi global menyentuh 85%**. Macro Average F1-Score naik dari 0.52 (Model 1) menjadi 0.76.
- **Keberhasilan Penanganan Kelas Minoritas:** Bukti keberhasilan pemodelan ini terlihat paling jelas pada kelas minoritas Earthquake (gempa bumi). Meskipun hanya terdapat 5 sampel uji (support = 5), Model 2 berhasil mencapai nilai **Recall**

1.00 (100%), yang berarti tidak ada satu pun gambar gempa bumi yang gagal dideteksi. Nilai Precision yang terlihat rendah (0.36) pada kelas ini murni merupakan efek sensitivitas matematis akibat pembagi sampel uji yang sangat sedikit. Pada kelas mayoritas seperti Urban Fire dan Water Disaster, model berhasil mencapai F1-Score kelas industri di angka 0.90.

Classification Report Model 1				
	precision	recall	f1-score	support
Earthquake	0.15	0.60	0.24	5
Land_Slide	0.46	0.35	0.40	66
Urban_Fire	0.73	0.79	0.76	66
Water_Disaster	0.80	0.78	0.79	156
accuracy			0.68	293
macro avg	0.54	0.63	0.55	293
weighted avg	0.70	0.68	0.69	293

Classification Report Model 2				
	precision	recall	f1-score	support
Earthquake	0.31	0.80	0.44	5
Land_Slide	0.74	0.74	0.74	66
Urban_Fire	0.92	0.89	0.91	66
Water_Disaster	0.93	0.89	0.91	156
accuracy			0.86	293
macro avg	0.72	0.83	0.75	293
weighted avg	0.87	0.86	0.86	293

3.5. Kesimpulan Analisis

Perbandingan metrik akhir menunjukkan bahwa performa Model 2 (MobileNetV2) jauh lebih unggul dari Model 1. Kendala *overfitting* berhasil diatasi setelah beralih ke metode *Transfer Learning* dengan tambahan pengaturan pada AdamW dan *Cosine Annealing*. Selain itu, model ini tetap mampu mendeteksi gambar secara akurat walaupun jumlah data di beberapa kelas sangat minim. Mengingat skor evaluasinya yang sudah tinggi dan stabil, Model 2 ini bisa dibilang sudah cukup andal jika ingin diterapkan langsung ke dalam sistem deteksi awal untuk tanggap darurat bencana.

Bab 4

Kesimpulan

Berdasarkan hasil perancangan, pelatihan, dan evaluasi komparatif yang telah dilakukan terhadap kedua model klasifikasi citra bencana alam, dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. **Keterbatasan Arsitektur *From Scratch*:** Model 1, yang dibangun menggunakan arsitektur *Convolutional Neural Network* (CNN) dari awal, terbukti memiliki limitasi kapasitas dalam mengekstraksi fitur visual yang kompleks dari dataset. Hal ini ditunjukkan oleh fenomena *overfitting*, di mana akurasi pelatihan mencapai 75% namun akurasi validasi mengalami stagnasi di angka 64%. Model ini juga sangat rentan terhadap ketidakseimbangan data (*class imbalance*), menghasilkan akurasi global yang hanya mencapai 66% pada data pengujian, serta rentan melewatkan deteksi pada kelas minoritas.
2. **Keunggulan Pendekatan *Transfer Learning*:** Implementasi arsitektur *pre-trained* MobileNetV2 sebagai Model 2 terbukti jauh lebih efektif dalam menyelesaikan rumusan masalah. Berbekal kemampuan ekstraksi fitur yang sudah matang dari ImageNet, dipadukan dengan optimasi parameter tingkat lanjut (*optimizer* AdamW, *Cosine Annealing*, dan *Early Stopping*), Model 2 berhasil mencapai kondisi konvergensi yang sangat sehat (*Good Fit*) dengan meminimalkan *Validation Loss* hingga menyentuh kisaran 0.50.
3. **Peningkatan Performa Terukur:** Dilihat dari metrik akhirnya, Model 2 berhasil menaikkan akurasi global secara drastis hingga menyentuh 85%. Model ini juga terbukti bisa mengatasi masalah ketidakseimbangan data (*class imbalance*). Hal ini paling jelas terlihat dari nilai *Recall* yang mencapai 100% untuk kelas *Earthquake* yang sampel datanya paling sedikit. Di saat yang sama, model tetap bisa menjaga skor presisi dan *F1-Score* di angka 0.90 untuk kelas mayoritas seperti *Urban Fire* dan *Water Disaster*.
4. **Rekomendasi Pemodelan:** Sesuai dengan target awal proyek ini, penggunaan MobileNetV2 dengan metode *Transfer Learning* adalah pilihan yang paling pas

dan efisien. Karena beban komputasinya ringan namun tetap bisa mengenali gambar dengan akurat, model ini sangat cocok kalau nantinya mau dipakai langsung ke dalam sistem tanggap darurat untuk mendeteksi bencana di lapangan dengan cepat.

REFERENSI

Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009). Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition* (pp. 248-255). IEEE.

GeeksforGeeks. (2024). *MobileNetV2 Architecture in Computer Vision*. GeeksforGeeks. <https://www.geeksforgeeks.org/computer-vision/mobilenet-v2-architecture-in-computer-vision/>

Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.

IBM. (2024). *What is image classification?* IBM Think Topics. <https://www.ibm.com/think/topics/image-classification>

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 6(1), 1-48.